

Inteligência Computacional

Projeto Fase III

JOÃO OLIVEIRA Nº2023144718

DIOGO FERREIRA Nº2023141377

Descrição do Problema

A classificação automática de imagens é um problema central em diversas aplicações de visão por computador, exigindo modelos capazes de extrair características relevantes e generalizar para novos exemplos.

Neste trabalho pretende-se desenvolver um sistema de classificação de imagens robusto, aplicado a um conjunto de dados composto por cinco classes distintas, dando continuidade às fases anteriores do projeto, recorrendo agora a técnicas de aprendizagem por transferência.

Nesta fase, para além dos algoritmos swarm utilizados anteriormente, foi também incluído um método de Random Search como abordagem de referência.

Esta comparação permite avaliar a vantagem de métodos de inteligência coletiva face a uma pesquisa aleatória.

Objetivos

A fase III do projeto tem como principal objetivo a construção de um modelo final de classificação de imagens recorrendo a aprendizagem por transferência.

Pretende-se otimizar apenas as camadas densas finais do modelo, comparar diferentes métodos de otimização de hiperparâmetros e analisar o impacto do número de instâncias de treino no desempenho do classificador.

Adicionalmente, procura-se validar o modelo em dados independentes e demonstrar o seu funcionamento em ambiente real através de uma aplicação web.

Descrição das Metodologias

Para a resolução do problema foi adotada uma abordagem baseada em aprendizagem por transferência, recorrendo a uma rede neuronal convolucional pré-treinada.

A arquitetura MobileNetV2 foi utilizada como extratora de características, mantendo as suas camadas base congeladas e adicionando uma rede densa final adaptada ao problema em estudo.

A otimização dos hiperparâmetros foi realizada exclusivamente nas camadas densas finais, utilizando algoritmos de inteligência coletiva, nomeadamente o Particle Swarm Optimization (PSO), o Whale Swarm Algorithm (WSA) e um método de Random Search.

Arquitetura Geral do Código

A arquitetura do código foi concebida de forma modular e sequencial, permitindo separar claramente as diferentes fases do processo de classificação de imagens. Esta organização garante uma correspondência direta entre a implementação e as etapas metodológicas definidas no projeto, facilitando a integração do modelo treinado em aplicações futuras.

- Aquisição das imagem
- Pré-processamento
- Modelo de classificação
- Módulo de otimização
- Avaliação e resultados

Arquitetura do Modelo de Classificação

O modelo de classificação adotado baseia-se numa rede neuronal convolucional pré-treinada, utilizada como extratora de características. Esta abordagem permite reaproveitar representações visuais aprendidas previamente, reduzindo o custo computacional e melhorando a capacidade de generalização do modelo.

- Arquitetura base: MobileNetV2
- Modelo pré-treinado no ImageNet
- Rede base utilizada apenas para extração de características
- Camadas finais adaptadas ao problema
- Classificação em cinco classes

Arquitetura da Aplicação Web

A aplicação web desenvolvida tem como objetivo demonstrar o funcionamento do sistema de classificação em ambiente real. Esta aplicação permite ao utilizador fornecer novas imagens e obter, em tempo real, a respetiva classificação recorrendo ao modelo previamente treinado e persistido.

- Implementada com o framework Streamlit
- Entrada de imagem por upload ou câmara
- Pré-processamento automático das imagens
- Utilização do modelo treinado e guardado
- Apresentação da classe prevista e nível de confiança

Implementação dos Algoritmos

A implementação dos algoritmos foi realizada de forma modular, permitindo integrar a aprendizagem por transferência com a otimização de hiperparâmetros através de algoritmos swarm.

- Preparação e balanceamento do dataset
- Modelo por transferência de aprendizagem
- Avaliação com subconjuntos fixos de treino e validação
- Otimização com PSO e WSA
- Treino final e avaliação

Otimização e Treino do Modelo

A otimização dos hiperparâmetros incidiu exclusivamente sobre as camadas densas finais do modelo, recorrendo a algoritmos swarm e Random Search para maximizar a accuracy de validação.

- Algoritmos: PSO, WSA e random search
- Hiperparâmetros: Número de neurónios, Taxa de aprendizagem
- Seleção baseada na accuracy de validação

Resultados da Otimização dos Hiperparâmetros


Procedeu-se à otimização dos hiperparâmetros da rede densa das camadas finais do modelo recorrendo a PSO, WSA e random search. Observa-se que, entre os métodos testados, o WSA apresentou o melhor desempenho em termos de accuracy de validação neste cenário.

Algoritmo	Neurónios	Learning Rate	Val Accuracy
PSO	512	0.000297	0.52
WSA	283	0.001204	0.68
Random Search	159	0.00274	0.54

Avaliação Final no Conjunto de Teste

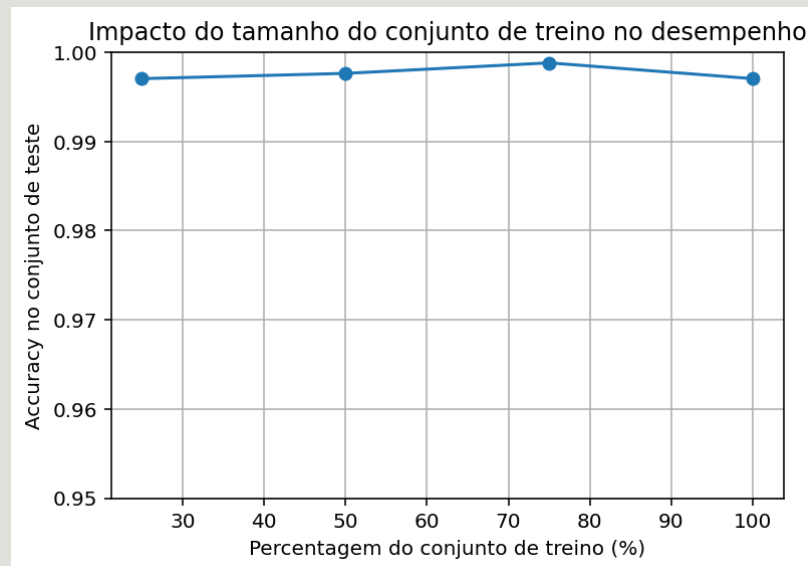
O modelo final foi avaliado num conjunto de teste independente. As métricas de classificação e a matriz de confusão demonstram um desempenho muito elevado em todas as classes, sem confusões significativas.

	precision	recall	f1-score	support
Apple	0.99	1.00	1.00	339
Banana	1.00	1.00	1.00	339
Kiwi	1.00	1.00	1.00	338
Orange	1.00	1.00	1.00	339
Peach	1.00	0.99	1.00	339
accuracy			1.00	1694
macro avg	1.00	1.00	1.00	1694
weighted avg	1.00	1.00	1.00	1694



Impacto do Tamanho do Conjunto de Treino

Foi analisado o impacto do tamanho do conjunto de treino no desempenho do modelo final. Os resultados mostram que a aprendizagem por transferência permite alcançar valores de accuracy elevados mesmo com uma fração reduzida dos dados de treino.



Porcentagem_Treino	Accuracy_Teste
0,25	0,997048378
0,5	0,997638702
0,75	0,998819351
1	0,997048378

Conclusões

Neste trabalho foi desenvolvido um sistema de classificação de imagens baseado em aprendizagem por transferência, recorrendo a uma rede neuronal convolucional pré-treinada.

A otimização dos hiperparâmetros das camadas densas finais permitiu melhorar o desempenho do modelo, tendo sido obtidos resultados muito elevados no conjunto de teste.

Os algoritmos baseados em inteligência coletiva demonstraram desempenho superior ao método de Random Search, validando a sua eficácia na otimização de hiperparâmetros.

A integração do modelo numa aplicação web demonstra a sua aplicabilidade em ambiente real, cumprindo os objetivos definidos no enunciado.